

# 矩阵分析及其应用

管华

2017-09-08 更新



# 目录

<b>第一章 矩阵基础知识</b>	<b>7</b>
1.1 线性空间与线性映射	7
1.1.1 线性空间与线性子空间	7
1.1.2 Euclid 空间、酉空间	8
1.1.3 线性映射及其矩阵表示	10
1.1.4 几个重要的线性子空间及其性质	10
1.2 矩阵的数值特征	10
1.2.1 秩	10
1.2.2 行列式	10
1.2.3 迹	11
1.2.4 特征值、特征向量和特征多项式	11
1.3 矩阵的标准形	11
1.3.1 等价变换下的标准形	11
1.3.2 相似变换下的 Jordan 标准形	12
1.3.3 相合变换下的标准形	13
1.4 半正定和正定矩阵	13
1.5 矩阵求逆公式	13
1.5.1 Leverrier-Faddeev 算法	13
1.5.2 分块求逆公式	13
1.5.3 Sherman-Motrison-Woodbury 公式	13
1.6 Hadamard 与 Kronecker 积	13
1.6.1 Hadamard 积及其性质	13
1.6.2 Kronecker 积及其性质	13

<b>第二章 向量范数和矩阵范数</b>	<b>15</b>
2.1 向量范数 . . . . .	15
2.1.1 向量范数的定义 . . . . .	15
2.1.2 常用向量范数 . . . . .	15
2.1.3 向量范数的分析性质 . . . . .	16
2.1.4 向量范数的代数性质 . . . . .	16
2.2 矩阵范数 . . . . .	17
2.2.1 矩阵范数的定义及分析性质 . . . . .	17
2.2.2 常用的矩阵范数 . . . . .	17
2.2.3 由向量范数诱导的矩阵范数 . . . . .	18
2.3 一些应用 . . . . .	18
2.3.1 谱半径与矩阵范数 . . . . .	18
2.3.2 矩阵逆与线性方程组解的扰动问题 . . . . .	19
2.3.3 条件数 . . . . .	19
<b>第三章 矩阵函数和矩阵微积分</b>	<b>21</b>
3.1 矩阵序列和矩阵级数 . . . . .	21
3.1.1 矩阵序列 . . . . .	21
3.1.2 矩阵级数 . . . . .	21
3.1.3 矩阵幂级数 . . . . .	22
3.2 矩阵函数 . . . . .	22
3.2.1 矩阵函数的定义与性质 . . . . .	22
3.2.2 矩阵函数值的计算 . . . . .	23
3.3 矩阵的微分和积分 . . . . .	24
3.3.1 以一元函数为元素的矩阵的微积分 . . . . .	24
3.3.2 函数对向量的微分 . . . . .	24
3.3.3 函数对矩阵的微分 . . . . .	26
3.3.4 矩阵对矩阵的微分 . . . . .	28
3.4 一些应用 . . . . .	28
3.4.1 特征多项式系数的表示 . . . . .	28
3.4.2 线性常系数微分方程组的求解 . . . . .	28
3.4.3 矩阵最优低秩逼近 . . . . .	28

<b>第四章</b>	<b>矩阵分解</b>	<b>29</b>
4.1	满秩分解 . . . . .	29
4.2	三角分解 . . . . .	29
4.2.1	LU 分解 . . . . .	29
4.2.2	LDU 分解 . . . . .	30
4.2.3	LU 分解的算法 . . . . .	30
4.2.4	Cholesky 分解 . . . . .	30
4.3	QR 分解 . . . . .	30
4.3.1	QR 分解 . . . . .	30
4.3.2	Gram-Schmidt 算法及其修正 . . . . .	30
4.3.3	Householder 变换法 . . . . .	30
4.3.4	Givens 旋转法 . . . . .	31
4.4	奇异值分解 . . . . .	31
4.4.1	定义及性质 . . . . .	31
4.4.2	极分解 . . . . .	31
4.5	矩阵的同时对角化 . . . . .	31
4.5.1	Hermite 矩阵和正规矩阵同时对角化 . . . . .	31
4.5.2	广义奇异值分解 . . . . .	31
4.6	一些应用 . . . . .	31
4.6.1	随机向量的模拟 . . . . .	31
4.6.2	基于 QR 分解的最小二乘算法 . . . . .	31
4.6.3	矩阵的最优逼近 . . . . .	31
<b>第五章</b>	<b>特征值分析</b>	<b>33</b>
5.1	特征值的连续性 . . . . .	33
5.2	特征值的估计 . . . . .	33
5.2.1	特征值的界 . . . . .	33
5.2.2	特征值所在的区域 . . . . .	33
5.3	Hermite 矩阵的特征值及其极性 . . . . .	33
5.3.1	Rayleigh 商 . . . . .	33
5.3.2	广义 Rayleigh 商 . . . . .	33
5.3.3	特征值的分隔 . . . . .	34
5.3.4	Hermite 扰动下的特征值 . . . . .	34
5.4	一些应用 . . . . .	34

5.4.1	与对角矩阵相似的矩阵特征值的扰动 . . . . .	34
5.4.2	主成分分析 . . . . .	34
5.4.3	概率分布的 Wasserstein 距离 . . . . .	34
<b>第六章</b>	<b>广义逆矩阵</b>	<b>35</b>
6.1	投影矩阵 . . . . .	35
6.2	广义逆矩阵及其性质 . . . . .	35
6.2.1	广义逆的定义 . . . . .	35
6.2.2	广义逆的性质 . . . . .	36
6.2.3	广义逆的等价形式 . . . . .	36
6.2.4	广义逆的反序法则 . . . . .	36
6.2.5	广义逆矩阵的连续性问题 . . . . .	36
6.3	广义逆的计算方法 . . . . .	36
6.3.1	单个矩阵的广义逆 . . . . .	36
6.3.2	更新矩阵的广义逆 . . . . .	36
6.3.3	分块算法 . . . . .	36
6.4	一些应用 . . . . .	36
6.4.1	矩阵方程、线性方程组的解与广义逆 . . . . .	36
6.4.2	精确初始化的最小二乘递推算法 . . . . .	36

# 第一章 矩阵基础知识

## 1.1 线性空间与线性映射

### 1.1.1 线性空间与线性子空间

定义 1.1.1 (线性空间/向量空间)

三个条件:

- $V$  在数域  $F$
- 加法运算
- 数乘运算

定义 1.1.2 (基)

$e_1, \dots, e_n \in \mathbb{C}^n$

若  $x$  在该基下的线性表示为

$$x = x_1 v_1 + \dots + x_n v_n$$

则称  $x_1, \dots, x_n$  为向量  $x$  在该坐标系中的坐标或分量, 并将向量  $x$  记为

$$x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$$

$$v_1 = a_{11}u_1 + \dots + a_{n1}u_n \quad (1.1.1)$$

$$\vdots \quad (1.1.2)$$

$$v_n = a_{1n}u_1 + \dots + a_{nn}u_n \quad (1.1.3)$$

称矩阵

$$\mathbf{A} = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix}$$

为由基  $\mathbf{u}_1, \dots, \mathbf{u}_n$  变为基  $\mathbf{v}_1, \dots, \mathbf{v}_n$  的过渡矩阵, 并称

$$[\mathbf{v}_1, \dots, \mathbf{v}_n] = [\mathbf{u}_1, \dots, \mathbf{u}_n] \mathbf{A}$$

为基变换公式。

某个向量在  $\mathbf{u}_1, \dots, \mathbf{u}_n$  和基  $\mathbf{v}_1, \dots, \mathbf{v}_n$  下的坐标分别为  $[x_1, \dots, x_n]^T$  和  $[y_1, \dots, y_n]^T$ , 则称

$$\begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = \mathbf{A} \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}$$

为基变换下向量坐标的变换公式。

### 定义 1.1.3 (线性子空间)

向量组  $\mathbf{x}_1, \dots, \mathbf{x}_n$  生成的子空间, 记为  $\text{span}\{\mathbf{x}_1, \dots, \mathbf{x}_n\}$

### 定义 1.1.4

直和 称子空间  $V_1 + V_2$  为  $V_1$  与  $V_2$  的直和, 记为  $V_1 \oplus V_2$

互补子空间 若  $V = V_1 \oplus V_2$ , 称  $V_1$  和  $V_2$  为互补子空间

## 1.1.2 Euclid 空间、酉空间

### 定义 1.1.5 (内积)

- 非负性
- 正定性  $\langle \mathbf{x}, \mathbf{x} \rangle = 0$  当且仅当  $\mathbf{x} = 0$
- 可加性
- 齐次性  $\langle a\mathbf{x}, \mathbf{y} \rangle = a\langle \mathbf{x}, \mathbf{y} \rangle$
- Hermite 性  $\langle \mathbf{x}, \mathbf{y} \rangle = \overline{\langle \mathbf{y}, \mathbf{x} \rangle}$

称函数  $\langle \cdot, \cdot \rangle: V \rightarrow F$  为  $V$  上的内积。

赋予了内积的 复和 实线性空间分别称为 酉空间和 Euclid 空间。



对任意两个向量  $\mathbf{x}, \mathbf{y} \in \mathbb{C}^n$ , 由

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{y}^T \mathbf{x}$$

定义的函数是  $\mathbb{C}^n$  上的内积, 从而  $\mathbb{C}^n$  为酉空间。

对任意两个矩阵  $\mathbf{A}, \mathbf{B} \in \mathbb{C}^{m \times n}$ , 由

$$\langle \mathbf{A}, \mathbf{B} \rangle = \sum_{i=1}^m \sum_{j=1}^n a_{ij} b_{ij}$$

定义的函数是  $\mathbb{C}^{m \times n}$  上的内积, 从而  $\mathbb{C}^{m \times n}$  为酉空间。

第一次阅读

1. 欧式空间就是酉空间
2. 酉空间的一个重要性质就是 **对称性**, 即 Hermite 性。
3. 正定性即是, 永远保持自己是整数, 仅当为 0 时取 0
4. 齐次性就是倍数

#### 定义 1.1.6

设  $V$  为酉空间, 且  $SS, SS_1, SS_2$  均为  $V$  的子空间。

向量  $\mathbf{x}, \mathbf{y} \in V$  正交, 记为  $\mathbf{x} \perp \mathbf{y}$   $\langle \mathbf{x}, \mathbf{y} \rangle = 0$

向量  $\mathbf{x}$  正交于子空间  $SS$   $\mathbf{x}$  与子空间  $SS$  中所有向量正交

$SS_1, SS_2$  为正交子空间  $SS_1$  中的任意向量均正交于子空间  $SS_2$

$SS$  的正交补子空间, 记为  $SS^\perp$

#### 定义 1.1.7

线性映射线性变换

$$T[\mathbf{v}_1, \dots, \mathbf{v}_n] = [\mathbf{u}_1, \dots, \mathbf{u}_m] \mathbf{A}$$

#### 定义 1.1.8 (正交变换/酉变换)

$$\langle \mathbf{x}, \mathbf{x} \rangle = \langle T\mathbf{x}, T\mathbf{x} \rangle$$

正交矩阵/酉矩阵

向量内积, 向量长度, 两个非零向量的夹角均是正交变换下的不变量。

$U \in R^{n \times n}$  为正交矩阵的充要条件是  $UU^T = I$

若矩阵  $U \in R^{m \times n}$  满足  $UU^T = I$ , 则称  $U$  为列正交矩阵。

定义 1.1.9 (对称变换/ Hermite 变换)

]

$$\langle Tx, y \rangle = \langle x, Ty \rangle$$

$A$  为对称矩阵的充要条件是  $A = A^T$

### 1.1.3 线性映射及其矩阵表示

定义 1.1.10

定义 1.1.11

定义 1.1.12

### 1.1.4 几个重要的线性子空间及其性质

定义 1.1.13

定义 1.1.14

## 1.2 矩阵的数值特征

### 1.2.1 秩

定义 1.2.1 (秩)

$A \in \mathbb{C}^{m \times n}$  的值域的维数, 记为  $\text{rank } A$

$A$  的零空间的维数, 记为  $n(A)$

定义 1.2.2

### 1.2.2 行列式

定义 1.2.3

代数余子式  $\mathbf{A} = (a_{ij}) \in \mathbb{C}^{n \times n}$  中去掉第  $i$  行和第  $j$  列元素后剩下的行列式，再乘以系数  $(-1)^{i+j}$ 。

$(\mathbf{A}_{ij})$  所有代数余子式构成的矩阵

### 1.2.3 迹

**定义 1.2.4 (迹)**

$\mathbf{A}$  的主对角线元素之和

$$\text{tr } \mathbf{A} = \sum_{i=1}^n a_{ii}$$

### 1.2.4 特征值、特征向量和特征多项式

**定义 1.2.5**

特征多项式  $\det(\lambda \mathbf{I} - \mathbf{A})$

特征值  $\lambda$   $\lambda$  是  $\det(\lambda \mathbf{I} - \mathbf{A})$  的根

特征向量  $\mathbf{x}$   $\mathbf{Ax} = \lambda \mathbf{x}$

特征对  $(\lambda, \mathbf{x})$

**定义 1.2.6**

谱  $\lambda(\mathbf{A})$  所有特征值的集合

谱半径  $\rho(\mathbf{A})$  最大特征值绝对值

特征子空间  $S_\lambda(\mathbf{A})$  特征向量构成的空间

## 1.3 矩阵的标准形

### 1.3.1 等价变换下的标准形

**定义 1.3.1 (行阶梯矩阵)**

1. 每行的第一个元素一般为 1
2. 1 的头上列全是 0

3. 全 0 行在底下

$$\begin{bmatrix} 0 & 1 & -2 & 0 & -1 & 3 \\ 0 & 0 & 0 & 1 & 2 & 5 \\ 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

### 1.3.2 相似变换下的 Jordan 标准形

Schur 分解定理

Jordan 分解定理

定义 1.3.2

Jordan 块  $\mathbf{J}_j(\lambda)$   $j \times j$  上三角矩阵, 主对角线  $\lambda$ , 上面是 1

$$\mathbf{J}_j(\lambda) = \begin{bmatrix} \lambda & 1 & & & \\ & \lambda & 1 & & \\ & & \lambda & \ddots & \\ & & & \ddots & 1 \\ & & & & \lambda \end{bmatrix}$$

Jordan 矩阵  $\mathbf{J}$  把 Jordan 块放在对角线上  $\sum n_i = n$

$$\mathbf{J} = \begin{bmatrix} \mathbf{J}_{n_1}(\lambda_1) & & \\ & \ddots & \\ & & \mathbf{J}_{n_k}(\lambda_k) \end{bmatrix}$$

Jordan 标准形 加个限制条件:  $\mathbf{J}$  与  $\mathbf{A}$  相似

矩阵的可对角化

定义 1.3.3

### 1.3.3 相合变换下的标准形

**定义 1.3.4** ( $A$  的惯性)

就是一个三元组, 记为  $\text{In } A$

$$(i_+(A), i_-(A), i_0(A))$$

- $A \in \mathbb{C}^{n \times n}$  为对称矩阵 **Hermite 矩阵**
- $i_+(A), i_-(A), i_0(A)$  分别为  $A$  的正、负和零特征值的个数

## 1.4 半正定和正定矩阵

### 1.5 矩阵求逆公式

1.5.1 Leverrier-Faddeev 算法

1.5.2 分块求逆公式

1.5.3 Sherman-Mottrison-Woodbury 公式

## 1.6 Hadamard 与 Kronecker 积

1.6.1 Hadamard 积及其性质

**定义 1.6.1** (Hadamard 积)

$A, B$  对应位置元素相乘得到的新矩阵, 记为  $A \odot B$

**定义 1.6.2** (矩阵的向量化)

就是把矩阵的每一行首尾连接起来形成一个大向量, 记为  $\text{vec}(A)$

1.6.2 Kronecker 积及其性质

**定义 1.6.3** (Kronecker 积)

把  $A$  中每个  $a_{ij}$  变成  $a_{ij}B$ , 记为  $A \otimes B$

**定义 1.6.4**



## 第二章 向量范数和矩阵范数

### 2.1 向量范数

#### 2.1.1 向量范数的定义

定义 2.1.1 (向量范数是酉不变的)

向量乘以一个酉矩阵之后范数大小不变

$$\|Ux\| = \|x\|$$

#### 2.1.2 常用向量范数

定义 2.1.2 (1-范数或  $l_1$  范数)

$\|x\|_1$  向量元素绝对值之和

定义 2.1.3 (2-范数或  $l_2$  范数)

$\|x\|_2$  向量元素平方和的开方

定义 2.1.4 (p-范数或  $l_p$  范数)

$$\|x\|_p = \left( \sum |x_i|^p \right)^{\frac{1}{p}}$$

定义 2.1.5 ( $\infty$ -范数或  $l_\infty$  范数)

$\|x\|_\infty$  向量元素的最大绝对值

定义 2.1.6 (加权范数  $\|x\|_A$ )

$A$  是对称正定矩阵

$$\|x\|_A = \left( x^T A x \right)^{\frac{1}{2}}$$

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$$

$$\|\mathbf{x}\|_1 = \sum |x_i| \quad (2.1.1)$$

$$\|\mathbf{x}\|_2 = \left( \sum |x_i|^2 \right)^{\frac{1}{2}} \quad (2.1.2)$$

$$\|(\|\mathbf{x}\|_\infty = \max_{i \leq n} |x_i| \quad (2.1.3)$$

**定义 2.1.7 (Hölder 不等式)**

$$\frac{1}{p} + \frac{1}{q} = 1$$

$$\sum |x_i y_i| \leq \left( \sum |x_i|^p \right)^{\frac{1}{p}} \left( \sum |y_i|^q \right)^{\frac{1}{q}}$$

$$\text{内积} \leq \text{范数} \|a\|_p \cdot \text{范数} \|b\|_q$$

**定义 2.1.8 (Minkowski 不等式)**

$$\left( \sum |x_i + y_i|^p \right)^{\frac{1}{p}} \leq \left( \sum |x_i|^p \right)^{\frac{1}{p}} + \left( \sum |y_i|^p \right)^{\frac{1}{p}}$$

$$\|a \oplus b\|_p \leq \|a\|_p + \|b\|_p$$

**定义 2.1.9 (加权范数)**

$\mathbf{A}$  is  $n \times n$  是 Hermite 正定矩阵

$$\|\mathbf{x}\|_{\mathbf{A}} = \left( \mathbf{x}^T \mathbf{A} \mathbf{x} \right)^{\frac{1}{2}}$$

### 2.1.3 向量范数的分析性质

所有向量范数都是等价的。

### 2.1.4 向量范数的代数性质

**定义 2.1.10**

$\mathbf{A}$  满秩, 则  $\mathbf{A}^T \mathbf{A}$  为 Hermite 正定矩阵, 从而

$$\|\mathbf{x}\|_{\mathbf{A}} = \|\mathbf{A} \mathbf{x}\|$$



## 2.2 矩阵范数

### 2.2.1 矩阵范数的定义及分析性质

**定义 2.2.1** ((广义) 矩阵范数是酉不变的)

矩阵前后乘以两个酉矩阵范数大小不变

$$\|UAV\| = \|A\|$$

**定理 2.2.1**

矩阵范数也具有与向量范数一样的等价性。

**定义 2.2.2** (矩阵范数与向量范数相容)

$A$  is  $m \times n$ ,  $x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$

$$\|Ax\|_V \leq \|A\|_M \|x\|_V$$

**定理 2.2.2**

$\|\cdot\|_M$  是  $n \times n$  上的矩阵范数  $\|\cdot\|_V$  是  $n$  上的矩阵范数可以得到

$$\|Ax\|_V = \|A\|_M \|x\|_V$$

$\|\cdot\|_M$  与  $\|\cdot\|_V$  相容。

### 2.2.2 常用的矩阵范数

**定义 2.2.3** ( $l_1$  范数)

$$\|A\|_{m_1} = \sum \sum |a_{ij}|$$

**定义 2.2.4** ( $l_2$  范数, Euclid 范数, Frobenius 范数)

$$\|A\|_F = \left( \sum \sum |a_{ij}|^2 \right)^{\frac{1}{2}}$$

重要:

$$\|AB\|_F^2 = \|A\|_F^2 \|B\|_F^2$$

$$\|A\|_F^2 = \text{Tr}(A^T A)$$

$$\|Ax\|_2 = \|A\|_F \|x\|_2$$

$\|\cdot\|_{m_\infty}$  是广义矩阵范数不是矩阵范数。

### 2.2.3 由向量范数诱导的矩阵范数

**定义 2.2.5** (向量范数诱导的矩阵范数)

$\mathbf{A}$  is  $m \times n$

$$\|\mathbf{A}\| = \max_{\|x\|=1} \|\mathbf{A}x\| = \max_{x \neq 0} \frac{\|\mathbf{A}x\|}{\|x\|}$$

与向量范数相容。

**定理 2.2.3**

任何向量范数都可以诱导出相应的矩阵范数。

**定理 2.2.4**

列和范数  $\|\mathbf{A}\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|$

谱范数  $\|\mathbf{A}\|_2 = \sqrt{\lambda_1}$ ,  $\lambda_1$  为  $\mathbf{A}^T \mathbf{A}$  的最大特征值

行和范数  $\|\mathbf{A}\|_\infty = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|$

## 2.3 一些应用

### 2.3.1 谱半径与矩阵范数

**定理 2.3.1**

$$\|\mathbf{A}\|_2 = \rho^{\frac{1}{2}}(\mathbf{A}^T \mathbf{A}) = \rho^{\frac{1}{2}}(\mathbf{A} \mathbf{A}^T)$$

若  $\mathbf{A}$  为 Hermite 矩阵, 则

$$\|\mathbf{A}\| = \rho(\mathbf{A})$$

对于一般矩阵范数, 任意矩阵的谱半径均被矩阵范数数值所控制。

**定理 2.3.2**

$\mathbf{A}$  is  $n \times n$

$$\rho(\mathbf{A}) = \|\mathbf{A}\|$$

**推论 2.3.1**

虽然谱半径不是矩阵范数, 但是对每个固定的方阵  $\mathbf{A}$ , 谱半径是关于  $\mathbf{A}$  的所有矩阵数值的下确界。

### 2.3.2 矩阵逆与线性方程组解的扰动问题

$$\mathbf{A}\mathbf{x} = \mathbf{b}$$

定义 2.3.1

$$\kappa = \|\mathbf{A}\| \|\mathbf{A}\|^{-1}$$

若  $\kappa$  越大, 则方程组解的相对误差也越大。

### 2.3.3 条件数

定义 2.3.2 (条件数)

$\mathbf{A}$  is  $n \times n$  非奇异,  $\|\mathbf{A}\| \|\mathbf{A}^{-1}\|$  是条件数, 记为  $\text{cond}(\mathbf{A})$

$$\text{cond}_2(\mathbf{A}) = \|\mathbf{A}\|_2 \|\mathbf{A}^{-1}\|_2$$

定理 2.3.3

$\mathbf{A}$  is  $n \times n$  非奇异

1.  $\text{cond}(\alpha \mathbf{A}) = \text{cond}(\mathbf{A}) = \text{cond}(\mathbf{A})$
2.  $\text{cond}_p(\mathbf{A}) \geq 1$
- 3.

$$\text{cond}_2(\mathbf{A}) = \left( \frac{\lambda_{\max}(\mathbf{A}^T \mathbf{A})}{\lambda_{\min}(\mathbf{A}^T \mathbf{A})} \right)^{\frac{1}{2}} \quad (2.3.1)$$

若  $\mathbf{A}$  为 Hermite 矩阵, 则

$$\text{cond}_2(\mathbf{A}) = \frac{\lambda_{\max}(\mathbf{A})}{\lambda_{\min}(\mathbf{A})} \quad (2.3.2)$$

4.  $\text{cond}_2^2(\mathbf{A}) = \text{cond}_2(\mathbf{A}^T \mathbf{A})$

当条件数  $\text{cond}(\mathbf{A})$  的值很大时, 我们称  $\mathbf{A}$  为病态的。



## 第三章 矩阵函数和矩阵微积分

### 3.1 矩阵序列和矩阵级数

#### 3.1.1 矩阵序列

##### 引理 3.1.1

$A$  是  $n \times n$ , 若存在一种矩阵范数  $\|\cdot\|$  使得  $\|A\| < 1$ , 则  $A^k \rightarrow O$ 。

##### 定理 3.1.1

设  $A$  是  $n \times n$ , 则  $A^k \rightarrow O \iff \rho(A) < 1$

##### 定义 3.1.1 (收敛矩阵)

$A$  是  $n \times n$

$$A^k \rightarrow O$$

##### 定义 3.1.2 (界)

$$|a_{ij}^{(k)}| < C$$

并称  $C$  为  $\{A^{(k)}\}$  的界。

##### 推论 3.1.1

$$\|A^k\|^{\frac{1}{k}} \rightarrow \rho(A)$$

#### 3.1.2 矩阵级数

##### 定义 3.1.3 (矩阵级数)

$$A^{(0)} + A^{(1)} + \cdots + A^{(k)} + \cdots = \sum A^{(k)}$$

**定义 3.1.4**

矩阵级数是发散的

绝对收敛

**3.1.3 矩阵幂级数****定理 3.1.2 (幂级数)**

$$\sum \mathbf{A}^k = \mathbf{I} + \mathbf{A} + \mathbf{A}^2 + \cdots + \mathbf{A}^k + \cdots = (\mathbf{I} - \mathbf{A})^{-1}$$

收敛的充要条件是  $\mathbf{A}$  为收敛矩阵, 且在收敛是, 其和为  $(\mathbf{I} - \mathbf{A})^{-1}$ .

**定理 3.1.3**

$f(z) = \sum c_k z^k$  的收敛半径为  $r$ . 若  $\mathbf{A}$  is  $n \times n$  满足  $\rho(\mathbf{A}) < r$ , 则矩阵幂级数  $\sum c_k \mathbf{A}^k$  **绝对收敛**; 若  $\rho(\mathbf{A}) > r$ , 则矩阵幂级数发散。

**3.2 矩阵函数****3.2.1 矩阵函数的定义与性质****定义 3.2.1**

当矩阵  $\mathbf{A}$  is  $n \times n$  的谱半径  $\rho(\mathbf{A}) < r$  时, 矩阵幂级数  $\sum c_k \mathbf{A}^k$  收敛, 称其和为 **矩阵函数**, 记为

$$f(\mathbf{A}) = \sum_0^{\infty} c_k \mathbf{A}^k$$

**例 3.2.1**

$$\begin{cases} f(z) = \frac{1}{1-z} = \sum z^k, & |z| < 1 \\ f(\mathbf{A}) = \sum \mathbf{A}^k = (\mathbf{I} - \mathbf{A})^{-1}, & \rho(\mathbf{A}) < 1 \end{cases}$$

■

**定理 3.2.1**

若  $\mathbf{A}, \mathbf{B}$  可交换, 即  $\mathbf{AB} = \mathbf{BA}$ , 则

$$e^{\mathbf{A}} e^{\mathbf{B}} = e^{\mathbf{B}} e^{\mathbf{A}} = e^{\mathbf{A}+\mathbf{B}}$$

同时,

$$\begin{cases} e^A e^{-A} = e^{-A} e^A = I \\ (e^A)^{-1} = e^{-A} \\ (e^A)^k = e^{kA} \end{cases}$$

### 3.2.2 矩阵函数值的计算

待定系数法

数项级数求和法

对角形法

若  $\mathbf{A}$  是  $n \times n$  相似于对角矩阵  $\Lambda$ , 即存在非奇异矩阵  $\mathbf{P}$ , 使得

$$\mathbf{P}^{-1} \mathbf{A} \mathbf{P} = \Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$$

则有

$$f(\mathbf{A}) = \mathbf{P} \cdot \text{diag}(f(\lambda_1), \dots, f(\lambda_n)) \cdot \mathbf{P}^{-1}$$

当  $\mathbf{A}$  相似于对角矩阵是, 矩阵幂级数的求和问题可以转化为求变换矩阵的问题。

**Jordan 标准形法**

**定义 3.2.2**

设  $\mathbf{A}$  的 Jordan 标准形为  $\mathbf{J}$ , 则存在可逆矩阵  $\mathbf{P}$  使得

$$\begin{cases} \mathbf{P}^{-1} \mathbf{A} \mathbf{P} = \mathbf{J} = \text{diag}(\mathbf{J}_1, \dots, \mathbf{J}_s) \\ f(\mathbf{A}) = \mathbf{P} \cdot \text{diag}(f(\mathbf{J}_1), \dots, f(\mathbf{J}_s)) \cdot \mathbf{P}^{-1} \end{cases}$$

去掉了收敛矩阵的限制。

**定理 3.2.2**

对于  $f(\mathbf{A})$  与矩阵的 Jordan 标准形  $\mathbf{J}$  中 Jordan 块的排列顺序无关, 与变换矩阵  $\mathbf{P}$  的选取无关。函数可相加, 可相乘。

$$\begin{cases} f(z) = f_1(z) + f_2(z) \implies f(\mathbf{A}) = f_1(\mathbf{A}) + f_2(\mathbf{A}) \\ f(z) = f_1(z)f_2(z) \implies f(\mathbf{A}) = f_1(\mathbf{A})f_2(\mathbf{A}) \end{cases}$$

### 3.3 矩阵的微分和积分

#### 3.3.1 以一元函数为元素的矩阵的微积分

$$\mathbf{A}(t) = \begin{bmatrix} a_{11}(t) & \cdots & a_{1n}(t) \\ \vdots & & \vdots \\ a_{m1}(t) & \cdots & a_{mn}(t) \end{bmatrix}$$

#### 3.3.2 函数对向量的微分

##### 定义 3.3.1

设  $f(\mathbf{x})$  为纯量函数, 其中  $\mathbf{x} = [x_1, \cdots, x_n]^T \in \mathbb{C}^n$ , 则

$$\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial f(\mathbf{x})}{\partial x_1} \\ \vdots \\ \frac{\partial f(\mathbf{x})}{\partial x_n} \end{bmatrix}$$

**例 3.3.1**  $\mathbf{A}$  is  $n \times n$ ,  $\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$

$$f(\mathbf{x}) = \mathbf{x}^T \mathbf{A} \mathbf{x} = \sum \sum a_{ij} x_i x_j$$

对  $\forall k = 1, \cdots, n$ , 有

$$\frac{\partial f(\mathbf{x})}{\partial x_k} = \frac{\partial}{\partial x_k} \left( \sum \sum a_{ij} x_i x_j \right) = \sum a_{ik} x_i + \sum a_{kj} x_j$$

所以

$$\frac{\partial \mathbf{x}^T \mathbf{A} \mathbf{x}}{\partial \mathbf{x}} = \mathbf{A} \mathbf{x} + \mathbf{A}^T \mathbf{x}$$

若  $\mathbf{A}$  为对称矩阵, 则

$$\frac{\partial \mathbf{x}^T \mathbf{A} \mathbf{x}}{\partial \mathbf{x}} = 2 \mathbf{A} \mathbf{x}$$

■



**定义 3.3.2**

$$\mathbf{x} = \begin{bmatrix} \vdots \\ x_n \end{bmatrix}_{[n \times 1]}, f(\mathbf{x}) = [f_1(\mathbf{x}), \dots, f_m(\mathbf{x})]_{1 \times m}$$

$$\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial f_1(\mathbf{x})}{\partial x_1} & \dots & \frac{\partial f_m(\mathbf{x})}{\partial x_1} \\ \vdots & & \vdots \\ \frac{\partial f_1(\mathbf{x})}{\partial x_n} & \dots & \frac{\partial f_m(\mathbf{x})}{\partial x_n} \end{bmatrix}_{n \times m}$$

**定义 3.3.3 (Jacobi 矩阵)**

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}_{[n \times 1]}, f(\mathbf{x}) = \begin{bmatrix} f_1(\mathbf{x}) \\ \vdots \\ f_m(\mathbf{x}) \end{bmatrix}$$

$$\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}^T} = \begin{bmatrix} \frac{\partial f_1(\mathbf{x})}{\partial x_1} & \dots & \frac{\partial f_1(\mathbf{x})}{\partial x_n} \\ \vdots & & \vdots \\ \frac{\partial f_m(\mathbf{x})}{\partial x_1} & \dots & \frac{\partial f_m(\mathbf{x})}{\partial x_n} \end{bmatrix}_{m \times n}$$

**定理 3.3.1 (链式法则)**

$$\frac{\partial f}{\partial \mathbf{x}} = \frac{\partial \mathbf{y}^T}{\partial \mathbf{x}} \frac{\partial f}{\partial \mathbf{y}} \iff \frac{\partial f(\mathbf{y}(\mathbf{x}))}{\partial \mathbf{x}} = \frac{\partial (\mathbf{y}(\mathbf{x}))^T}{\partial \mathbf{x}} \frac{\partial f(\mathbf{y})}{\partial \mathbf{y}}$$

**定义 3.3.4**

$$\mathbf{x} = \begin{bmatrix} \vdots \\ x_n \end{bmatrix}$$

纯量函数关于向量的二阶微分是由  $n^2$  个二阶偏导组成的  $n \times n$  阶矩阵, 称为 Hessian 矩阵。

$$\frac{\partial^2 f(\mathbf{x})}{\partial \mathbf{x} \partial \mathbf{x}^T} = \frac{\partial}{\partial \mathbf{x}^T} \left( \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} \right)$$

$$\frac{\partial^2 f(\mathbf{x})}{\partial \mathbf{x} \partial \mathbf{x}^T} = \begin{bmatrix} \frac{\partial^2 f(\mathbf{x})}{\partial x_1 \partial x_1} & \cdots & \frac{\partial^2 f(\mathbf{x})}{\partial x_1 \partial x_n} \\ \vdots & & \vdots \\ \frac{\partial^2 f(\mathbf{x})}{\partial x_n \partial x_1} & \cdots & \frac{\partial^2 f(\mathbf{x})}{\partial x_n \partial x_n} \end{bmatrix}$$

特别的, 若  $f(\mathbf{x}) = \mathbf{x}^T \mathbf{A} \mathbf{x}$ , 则

$$\frac{\partial^2(\mathbf{x}^T \mathbf{A} \mathbf{x})}{\partial \mathbf{x} \partial \mathbf{x}^T} = \mathbf{A} + \mathbf{A}^T$$

**定义 3.3.5 (向量值函数  $f(\mathbf{x})$  对向量  $\mathbf{x}$  的微分)**

$$\mathbf{x} = [x_1, \dots, x_n]^T, \quad f(\mathbf{x}) = [f_1(\mathbf{x}), \dots, f_m(\mathbf{x})]^T$$

$$\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial f_1(\mathbf{x})}{\partial x_1} & \dots & \frac{\partial f_m(\mathbf{x})}{\partial x_1} \\ \vdots & & \vdots \\ \frac{\partial f_1(\mathbf{x})}{\partial x_n} & \dots & \frac{\partial f_m(\mathbf{x})}{\partial x_n} \end{bmatrix}$$

**定义 3.3.6 (Jacobi 矩阵)**

$$\mathbf{x} = [x_1, \dots, x_n]^T, \quad f(\mathbf{x}) = [f_1(\mathbf{x}), \dots, f_m(\mathbf{x})]^T$$

$$\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}^T} = \begin{bmatrix} \frac{\partial f_1(\mathbf{x})}{\partial x_1} & \dots & \frac{\partial f_1(\mathbf{x})}{\partial x_n} \\ \vdots & & \vdots \\ \frac{\partial f_m(\mathbf{x})}{\partial x_1} & \dots & \frac{\partial f_m(\mathbf{x})}{\partial x_n} \end{bmatrix}$$

**定义 3.3.7 (Hessian 矩阵)**

$$\frac{\partial^2 f(\mathbf{x})}{\partial \mathbf{x} \partial \mathbf{x}^T} = \frac{\partial}{\partial \mathbf{x}^T} \left( \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} \right) = \begin{bmatrix} \frac{\partial^2 f(\mathbf{x})}{\partial x_1 \partial x_1} & \dots & \frac{\partial^2 f(\mathbf{x})}{\partial x_1 \partial x_n} \\ \vdots & & \vdots \\ \frac{\partial^2 f(\mathbf{x})}{\partial x_n \partial x_1} & \dots & \frac{\partial^2 f(\mathbf{x})}{\partial x_n \partial x_n} \end{bmatrix}$$

若  $f(\mathbf{x}) = \mathbf{x}^T \mathbf{A} \mathbf{x}$ , 则

$$\frac{\partial^2(\mathbf{x}^T \mathbf{A} \mathbf{x})}{\partial \mathbf{x} \partial \mathbf{x}^T} = \mathbf{A} + \mathbf{A}^T$$

### 3.3.3 函数对矩阵的微分

**定义与性质**

**定义 3.3.8 (纯量函数  $f(\mathbf{A})$  对矩阵  $\mathbf{A}$  的微分定义)**

$$\frac{\partial f(\mathbf{A})}{\partial \mathbf{A}} = \begin{bmatrix} \frac{\partial f(\mathbf{A})}{\partial a_{11}} & \dots & \frac{\partial f(\mathbf{A})}{\partial a_{1n}} \\ \vdots & \ddots & \vdots \\ \frac{\partial f(\mathbf{A})}{\partial a_{m1}} & \dots & \frac{\partial f(\mathbf{A})}{\partial a_{mn}} \end{bmatrix}$$

**定理 3.3.2**

$$\frac{\partial g}{\partial \mathbf{A}} = \frac{\partial g}{\partial y} \frac{\partial y}{\partial \mathbf{A}} \iff \frac{\partial g(f(\mathbf{A}))}{\partial \mathbf{A}} = \frac{\partial g(y)}{\partial y} \frac{\partial f(\mathbf{A})}{\partial \mathbf{A}}$$

记  $\mathbf{E}_{ij} = \mathbf{e}_i \mathbf{e}_j^T$ , 即第  $i$  行第  $j$  列元素为 1, 其余元素为零的矩阵。

$$\frac{\partial (\mathbf{a}^T \mathbf{X}^{-1} \mathbf{b})}{\partial \mathbf{X}} = -(\mathbf{A}^{-1})^T \mathbf{a} \mathbf{b}^T (\mathbf{X}^{-1})^T$$

**迹的梯度矩阵****定理 3.3.3**

$$\begin{aligned} \frac{\partial \text{Tr} \mathbf{X}}{\partial \mathbf{X}} &= \mathbf{I} \\ \frac{\partial \text{Tr}(\mathbf{X}^{-1})}{\partial \mathbf{X}} &= -(\mathbf{X}^{-2})^T \end{aligned}$$

$$\text{Tr}(\mathbf{A} \mathbf{X}) = \sum_{i=1}^m \sum_{j=1}^n a_{ij} x_{ij}$$

**定理 3.3.4**

$$\begin{aligned} \frac{\partial \text{Tr}(\mathbf{A} \mathbf{X})}{\partial \mathbf{X}} &= \mathbf{A}^T \\ \frac{\partial \text{Tr}(\mathbf{A} \mathbf{X})}{\partial \mathbf{X}} &= \mathbf{A} + \mathbf{A}^T - \text{diag} \mathbf{A} \\ \frac{\partial \text{Tr}(\mathbf{A} \mathbf{X}^{-1})}{\partial \mathbf{X}} &= -(\mathbf{X}^{-1} \mathbf{A} \mathbf{X}^{-1})^T \end{aligned}$$

**定理 3.3.5**

$$\begin{aligned} \frac{\partial \text{Tr}(\mathbf{X}^T \mathbf{A} \mathbf{X})}{\partial \mathbf{X}} &= (\mathbf{A} + \mathbf{A}^T) \mathbf{X} \\ \frac{\partial \text{Tr}(\mathbf{X} \mathbf{A} \mathbf{X}^T)}{\partial \mathbf{X}} &= \mathbf{X} (\mathbf{A} + \mathbf{A}^T) \\ \frac{\partial \text{Tr}(\mathbf{A} \mathbf{X}^{-1} \mathbf{B})}{\partial \mathbf{X}} &= -(\mathbf{X}^{-1} \mathbf{B} \mathbf{A} \mathbf{X}^{-1})^T \end{aligned}$$

**行列式的梯度矩阵****定理 3.3.6**

若  $\mathbf{X}$  中的元素相互独立, 则

$$\frac{\partial \det \mathbf{X}}{\partial \mathbf{X}} = \det \mathbf{X} \cdot (\mathbf{X}^{-1})^T$$

若  $\mathbf{X}$  为对称矩阵, 则

$$\frac{\partial \det \mathbf{X}}{\partial \mathbf{X}} = \det \mathbf{X} \cdot (2\mathbf{X}^{-1} - \text{diag}(\mathbf{X}^{-1}))$$

**3.3.4 矩阵对矩阵的微分**

**定义 3.3.9** (矩阵  $F(\mathbf{X})$  对  $\mathbf{X}$  的微分)

$\mathbf{X} \in \mathbb{C}^{m \times n}$ ,  $f_{ij}(\mathbf{X})$  为  $mn$  元纯量函数 ( $i: 1 \rightarrow p, j: 1 \rightarrow q$ ), 记矩阵函数  $F(\mathbf{X}) = (f_{ij}(\mathbf{X}))$

$$\frac{\partial F(\mathbf{X})}{\partial \mathbf{X}} = \left[ \text{vec} \left( \frac{\partial f_{11}}{\partial \mathbf{X}} \right), \text{vec} \left( \frac{\partial f_{12}}{\partial \mathbf{X}} \right), \dots, \text{vec} \left( \frac{\partial f_{pq}}{\partial \mathbf{X}} \right) \right]$$

**3.4 一些应用****3.4.1 特征多项式系数的表示****3.4.2 线性常系数微分方程组的求解****3.4.3 矩阵最优低秩逼近**

## 第四章 矩阵分解

### 4.1 满秩分解

#### 定义 4.1.1 (满秩分解)

一个秩为  $r$  的矩阵被分解为一个列数为  $r$  的矩阵和一个行数为  $r$  的矩阵的乘积。

- $\mathbf{A} \in \mathbb{C}^{m \times n}$ ,  $r = \text{rank } \mathbf{A} > 0$
- $\mathbf{F} \in \mathbb{C}^{m \times r}$ , 满列秩矩阵
- $\mathbf{G} \in \mathbb{C}^{r \times n}$ , 满行秩矩阵

$$\mathbf{A} = \mathbf{F}\mathbf{G}$$

### 4.2 三角分解

#### 4.2.1 LU 分解

#### 定义 4.2.1 (LU 分解)

一个  $n \times n$  的矩阵可以分解为一个  $n$  阶的下三角矩阵和上三角矩阵。 $\mathbf{A}$  的绝对值等于  $\mathbf{U}$  对角线元素之积。

- $\mathbf{A} \in \mathbb{C}^{n \times n}$
- $\mathbf{L}$  为  $n$  阶下三角矩阵
- $\mathbf{U}$  为  $n$  阶上三角矩阵

$$\det \mathbf{A} = u_{11} \dots u_{nn}$$

### 4.2.2 LDU 分解

#### 定义 4.2.2 (LDU 分解)

一个  $n \times n$  矩阵可以分解为一个单位下三角矩阵  $\times$  一个对角矩阵  $\times$  单位上三角矩阵

$$A = LDU$$

### 4.2.3 LU 分解的算法

### 4.2.4 Cholesky 分解

#### 定义 4.2.3 (Cholesky 分解, 又叫平方根分解)

一个  $n \times n$  的对称正定矩阵被分解为一个下三角矩阵和它转置矩阵的乘积。

$$A = GG^T$$

- $A$  在  $\mathbb{C}^{n \times n}$  的 Hermite 正定矩阵, 对称正定矩阵
- $G$  下三角矩阵
- $G^T$  上三角矩阵

## 4.3 QR 分解

### 4.3.1 QR 分解

#### 定义 4.3.1 (QR 分解)

$$A = QR$$

- $A \in \mathbb{C}^{m \times n}$
- $Q \in \mathbb{C}^{m \times n}$  列正交矩阵
- $R \in \mathbb{C}^{n \times n}$  上三角矩阵

### 4.3.2 Gram-Schmidt 算法及其修正

### 4.3.3 Householder 变换法

#### 定义 4.3.2 (初等反射矩阵, 又叫 Householder 矩阵)

$$H_u = I - 2uu^T$$

### 4.3.4 Givens 旋转法

定义 4.3.3 (初等旋转矩阵, 又叫 Givens 矩阵)

设  $c^2 + s^2 = 1$   $G_{ij}$  是这样的一个矩阵, 对角线一般为 1, 除了  $g_{ii} = c$ ,  $g_{jj} = 1$ ,  $g_{ij} = -s$ ,  $g_{ji} = s$ , 记为  $G_{ij}(c, s)$ 。

## 4.4 奇异值分解

### 4.4.1 定义及性质

定义 4.4.1 (奇异值)

$$\sigma_i = \sqrt{\lambda_i}$$

注意:  $\lambda_i$  不是  $A$  的特征值!

- $A$  是  $m \times n$  的矩阵, 秩为  $r$
- 那么  $A^T A$  为半正定矩阵, 秩也为  $r$
- $A^T A$  的特征值  $\lambda_1, \dots, \lambda_n$  从大到小排列

### 4.4.2 极分解

## 4.5 矩阵的同时对角化

### 4.5.1 Hermite 矩阵和正规矩阵同时对角化

### 4.5.2 广义奇异值分解

## 4.6 一些应用

### 4.6.1 随机向量的模拟

### 4.6.2 基于 QR 分解的最小二乘算法

### 4.6.3 矩阵的最优逼近





## 第五章 特征值分析

### 5.1 特征值的连续性

### 5.2 特征值的估计

#### 5.2.1 特征值的界

#### 5.2.2 特征值所在的区域

### 5.3 Hermite 矩阵的特征值及其极性

#### 5.3.1 Rayleigh 商

定义 5.3.1 (Rayleigh 商)

$$R(x) = \frac{x^T A x}{x^T x}$$

#### 5.3.2 广义 Rayleigh 商

$A$   $n \times n$  Hermite 矩阵  $B$   $n \times n$  Hermite 正定矩阵

定义 5.3.2

$$\begin{aligned} Ax &= \lambda Bx \\ B^{-\frac{1}{2}} A B^{-\frac{1}{2}} \tilde{x} &= \lambda \tilde{x} \\ x &= B^{-\frac{1}{2}} \tilde{x} \end{aligned}$$

$\lambda$   $A$  相对于  $B$  的特征值

$x$   $A$  相对于  $B$  的属于  $\lambda$  的特征向量

定义 5.3.3 (矩阵  $A$  相对于矩阵  $B$  的广义 Rayleigh 商)

$$R(x) = \frac{x^T A x}{x^T B x}$$

### 5.3.3 特征值的分隔

### 5.3.4 Hermite 扰动下的特征值

## 5.4 一些应用

### 5.4.1 与对角矩阵相似的矩阵特征值的扰动

### 5.4.2 主成分分析

### 5.4.3 概率分布的 Wasserstein 距离

## 第六章 广义逆矩阵

### 6.1 投影矩阵

**定义 6.1.1 (投影矩阵)**

$\mathbf{x} \in \mathbb{C}^n$ , 这个空间可以被拆分为两个互补子空间 ( $\mathbb{C}^n = L \oplus M$ ), 称  $\mathbf{y}$  为  $\mathbf{x}$  沿着  $M$  到  $L$  上的投影。

$$\mathbf{x} = \mathbf{y} + \mathbf{z}, \quad \mathbf{y} \in L, \mathbf{z} \in M$$

投影算子  $\mathbf{x}$  到  $L$  的变换, 记为  $P_{L,M}$

投影矩阵 投影算子在标准正交基下对应的矩阵, 记为  $P_{L,M}$

**定义 6.1.2 (幂等矩阵)**

$$P^2 = P \quad n \times n$$

**定义 6.1.3 (正交投影算子/正交投影矩阵)**

$P_L$  到  $L$  上的正交投影算子

### 6.2 广义逆矩阵及其性质

#### 6.2.1 广义逆的定义

**定义 6.2.1**

### 6.2.2 广义逆的性质

### 6.2.3 广义逆的等价形式

#### 定义 6.2.2

### 6.2.4 广义逆的反序法则

### 6.2.5 广义逆矩阵的连续性问题

## 6.3 广义逆的计算方法

### 6.3.1 单个矩阵的广义逆

### 6.3.2 更新矩阵的广义逆

### 6.3.3 分块算法

## 6.4 一些应用

### 6.4.1 矩阵方程、线性方程组的解与广义逆

### 6.4.2 精确初始化的最小二乘递推算法